

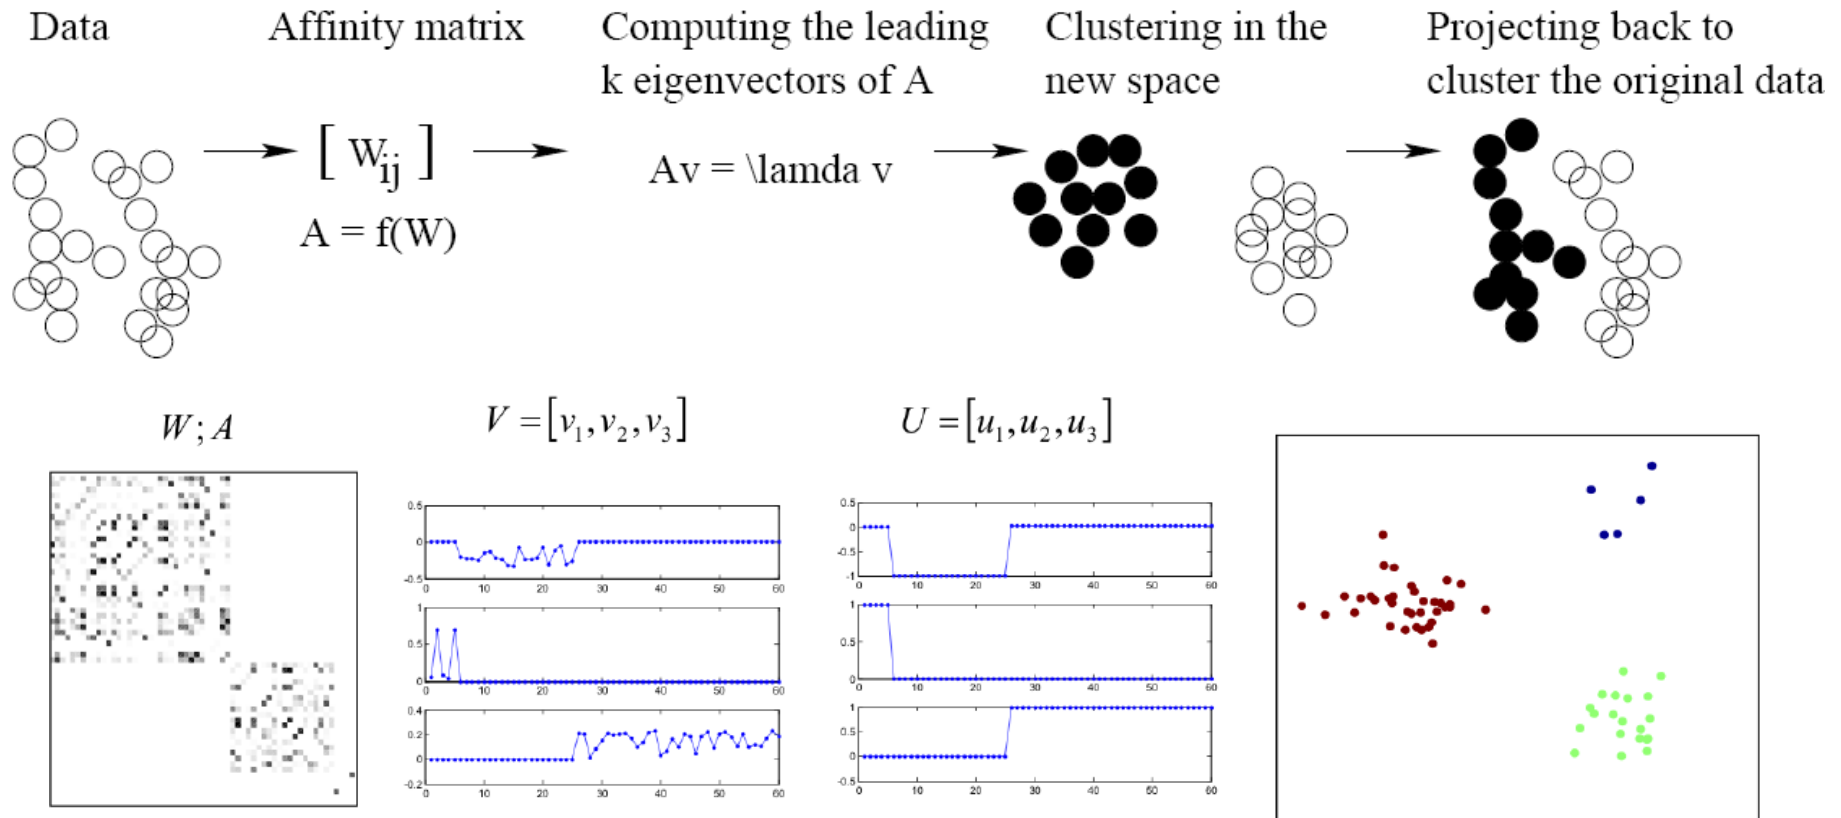
Thème 5: Méthodes avancées – partie 3

Clustering Spectral

Les diapos de cette partie viennent de Dr. Jiawei Han
et Dr. Ralf Möller Dr. Özgür L. Özçep

-
- ▶ Le diapo de Jiawei Han suivant illustre sommairement le fonctionnement de « spectral clustering »

Clustering spectral : illustrations et commentaires



- ▶ Clustering spectral : efficace dans des tâches telles que le traitement d'images
- ▶ Défi d'extensibilité : le calcul de vecteurs propres sur une grande matrice est coûteux
- ▶ Peut être combiné avec d'autres méthodes de clustering, telles que le bi-clustering

Une autre présentation de clustering spectral

- ▶ Prof. Dr. Ralf Möller Dr. Özgür L. Özçep
Universität zu Lübeck
Institut für Informationssysteme

Spectral Clustering

Acknowledgements for subsequent slides to


Xiaoli Fern

CS 534: Machine Learning 2011

<http://web.engr.oregonstate.edu/~xfern/classes/cs534/>

Clustering spectral

- ▶ Objets représentés comme sommets V d'un graphe G
- ▶ Sommets connectés par des arêtes E
- ▶ Les poids associés aux arêtes sont représentés par W
 - ▶ Grand $W(i,j)$ signifie que les objets i et j sont très similaires; petit $W(i,j)$ signifie dissimilaires.




- ▶ Les méthodes de clustering qui emploient le “spectre” de la matrice W sont des méthodes de clustering spectral.

Comment créer le graphe (de similitude)?


- ▶ On peut créer
 - ▶ Un graph à connexions complètes
 - ▶ Un graphe de K plus proches voisins (K-NN)
 - ▶ Un graphe de voisinage- ε (ε -neighborhood graph)
- ▶ En pratique, on utilise souvent le noyau gaussien pour calculer la similitude entre les objets :

$$W(i, j) = \exp \frac{-|x_i - x_j|^2}{\sigma^2}$$


kNN graph, $k = 5$



Mutual kNN graph, $k = 5$




epsilon-graph, $\epsilon = 0.3$



Motivations / Objectives

- ▶ Il y a de différentes façons d'interpréter le clustering spectral
 - ▶ On peut considérer le clustering spectral comme la recherche de partitions du graphe qui minimisent la « coupe normalisée » (Normalized Cut).
 - ▶ Alternativement, nous pouvons également considérer cela comme une marche aléatoire sur le graphe.



Partitionnement de graphe



Terminologies des graphes



- Degree of nodes

$$d_i = \sum_j w_{i,j}$$




- Volume of a set

$$vol(A) = \sum_{i \in A} d_i$$



Coupe de graphe (Graph Cut)

- Soit une partition d'un graphe en deux parties A et B



- $Cut(A, B)$: somme des poids de l'ensemble des arêtes reliant les deux groupes A et B

$$cut(A, B) = \sum_{i \in A, j \in B} w_{ij} = 0.3$$

- Objectif : trouver une partition A et B qui minimise $Cut(A, B)$


Coupe minimale (fonction objectif)

- ▶ Mincut : vise à minimiser le poids des connexions entre groupes

$$\min_{A \cap B = \emptyset, A \cup B = V} \text{Cut}(A, B)$$

- ▶ Problème :

- ▶ tend vers une solution dégénérative. Ex.




- ▶ Nécessite donc une approche favorisant une solution plus équilibrée

Coupe normalisée (Normalized Cut)

- Considérez la connectivité entre les groupes par rapport au volume de chaque groupe

$$Ncut(A, B) = \frac{cut(A, B)}{Vol(A)} + \frac{cut(A, B)}{Vol(B)}$$



$$Ncut(A, B) = cut(A, B) \frac{Vol(A) + Vol(B)}{Vol(A)Vol(B)}$$

- Le rapport des volumes ci-dessus est minimisé seulement lors que $Vol(A)$ et $Vol(B)$ sont égaux.

Objectif pour optimiser NCut

► Comment minimiser $NCut$?

Let W be the similarity matrix, $W(i, j) = W_{i,j}$;

Let D be the diag. matrix, $D(i, i) = \sum_j W(i, j)$;

Let x be a vector in $\{1, -1\}^N$, $x(i) = 1 \Leftrightarrow i \in A$.

► Après implications, on obtient

$$\min_x Ncut(x) = \min_y \frac{y^T (D - W)y}{y^T Dy}$$

Rayleigh quotient

Subject to: $y^T D \mathbf{1} = 0$ (y takes discrete values)

NP-Hard!

Résoudre Ncut

- ▶ Relâcher le problème d'optimisation en résolvant un système de valeurs propres généralisé dans le continu

$$\min_y y^T (D - W)y \text{ subject to } y^T D y = 1$$

- ▶ Lagrangienne :

$$L(y, \lambda) = y^T (D - W)y - \lambda(y^T D y - 1)$$



- ▶ En imposant les dérivés partiels par rapport à y à zéro

$$(D - W)y = \lambda D y$$

- ▶ Noter que $(D - W)1 = 0$, donc the premier vecteur propre est $y_0 = 1$, avec valeur propre 0.
- ▶ Le deuxième plus petit vecteur propre est la solution à valeur réelle de ce problème

2-way Normalized Cuts

1. Compute the affinity matrix W , compute the degree matrix (D), D is diagonal and $D(i, i) = \sum_{j \in V} W(i, j)$
2. Solve $(D - W)y = \lambda Dy$, where $D - W$ is called the Laplacian matrix
3. Use the eigenvector with the second smallest eigen-value to bipartition the graph into two parts.



Spectral embedding of the data